Opis problemu

Poniżej przedstawiona jest implementacja algorytmu **TD(0)** do problemu **random walk**.

Diagram:

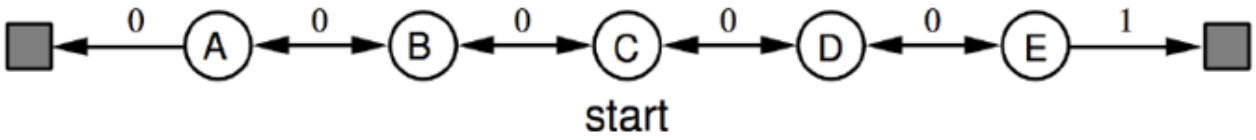

Przypomnijmy podstawowe fakty:

- **Kółkami** oznaczone są **stany nieterminalne**, **kwadratami stany terminalne**.
- Wszystkie **epizody rozpoczynają** się w środkowym stanie **C**.
- W dowolnym stanie nieterminalnym **prawdopodobieństwa ruchu w lewo i ruchu w prawo** są równe i wynoszą **0.5** (to jest polityka **pi**).
- Nad strzałkami widoczne są **wartości nagród**. Tylko przejście ze stanu **E** do **stanu terminalnego po prawej stronie** skutkuje nagrodą **R=1**. Poza tym wszystkie nagrody wynoszą **0**.

Algorytm

Implementujemy algorytm:

Tabular TD(0) for estimating v_π

Input: the policy π to be evaluated
Algorithm parameter: step size $\alpha \in (0, 1]$
Initialize $V(s)$, for all $s \in \mathcal{S}^+$, arbitrarily except that $V(terminal) = 0$

Loop for each episode:
  Initialize S
  Loop for each step of episode:
    $A \leftarrow$ action given by π for S
    Take action A, observe R, S'
    $V(S) \leftarrow V(S) + \alpha\big[R + \gamma V(S') - V(S)\big]$
    $S \leftarrow S'$
  until S is terminal

Implementacja

Zacznijmy od importu potrzebnej biblioteki:

```
import numpy as np
```

Stany oznaczamy cyframi począwszy od lewej strony:

- Stan terminalny *z lewej strony* - **0**
- Stan A - **1**
- Stan B - **2**
- Stan C - **3**

- Stan D - **4**
- Stan E - **5**
- Stan terminalny *z prawej strony* - **6**

Wartości początkowe **V** dla wszystkich stanów:

```
V = np.zeros(7)
print(V)
```

```
[0. 0. 0. 0. 0. 0. 0.]
```

```
epochs = 1000 #liczb epok czyli to ile epizodów uwzględnimy w wyliczeniu V (im więcej tym lepiej)
alpha = 0.1
gamma = 1.0 #bez zdyskontowania
#V = np.zeros(env.env.nS)


for i in range(epochs):
   state = 3 #stan poczatkowy w każdym epizodzie
   while True:
    action = np.random.randint(2)
    if action==0:
       next_state = state - 1
    else:
       next_state = state + 1
    if next_state == 6:
      R=1
    else:
      R=0
    V[state] = V[state] + alpha * (R + gamma*V[next_state] - V[state])
    state = next_state
    if state == 0 or state == 6:
      break
```

```
  #UWAGA: do losowania akcji (w prawo lub w lewo) można wykorzystać metodę np.random.randint(2), która zwraca liczbę 0 lub 1.
```

Wypiszmy wyliczone wartości **V**:

```
print(V)
```

```
    [0.         0.12165717 0.36829621 0.6220212  0.71323278 0.83126709
     0.        ]
```

Wartości **teoretyczne** podane w wykładzie (**slajd 19**):

```
print([0,1/6,2/6,3/6,4/6,5/6,0])
```

```
    [0, 0.16666666666666666, 0.3333333333333333, 0.5, 0.6666666666666666, 0.8333333333333334, 0]
```

Polecenie

Przetestuj działanie powyższego algorytmu dla **3 wybranych par wartości parametrów alpha i gamma**. Podaj wyliczone wartości **V**. Skomentuj uzyskane rezultaty.

DO UZUPEŁNIENIA

```
epochs = 1000 #liczb epok czyli to ile epizodów uwzględnimy w wyliczeniu V (im więcej tym lepiej)
alpha = 0.1
gamma = 1.0 #bez zdyskontowania
#V = np.zeros(env.env.nS)


for i in range(epochs):
   state = 3 #stan poczatkowy w każdym epizodzie
```

```
    while True:
     action = np.random.randint(2)
     if action==0:
        next_state = state - 1
     else:
        next_state = state + 1
     if next_state == 6:
       R=1
     else:
       R=0
     V[state] = V[state] + alpha * (R + gamma*V[next_state] - V[state])
     state = next_state
     if state == 0 or state == 6:
       break
```

```
print(V)
```

```
     [0.         0.11486275 0.32273098 0.51277344 0.75748966 0.90698853
      0.        ]
```

```
epochs = 1000 #liczb epok czyli to ile epizodów uwzględnimy w wyliczeniu V (im więcej tym lepiej)
alpha = 0.5
gamma = 0.5 #bez zdyskontowania
#V = np.zeros(env.env.nS)


for i in range(epochs):
   state = 3 #stan poczatkowy w każdym epizodzie
   while True:
    action = np.random.randint(2)
    if action==0:
       next_state = state - 1
    else:
       next_state = state + 1
    if next_state == 6:
```

```
        R=1
      else:
        R=0
      V[state] = V[state] + alpha * (R + gamma*V[next_state] - V[state])
      state = next_state
      if state == 0 or state == 6:
        break



print(V)
```

```
     [0.         0.00030345 0.00884711 0.02331741 0.10662654 0.19887943
      0.        ]
```

```
epochs = 1000 #liczb epok czyli to ile epizodów uwzględnimy w wyliczeniu V (im więcej tym lepiej)
alpha = 0.99
gamma = 0.1 #bez zdyskontowania
#V = np.zeros(env.env.nS)


for i in range(epochs):
   state = 3 #stan poczatkowy w każdym epizodzie
   while True:
    action = np.random.randint(2)
    if action==0:
       next_state = state - 1
    else:
       next_state = state + 1
    if next_state == 6:
      R=1
    else:
      R=0
    V[state] = V[state] + alpha * (R + gamma*V[next_state] - V[state])
    state = next_state
    if state == 0 or state == 6:
      break
```

```
print(V)
```

```
[0.00000000e+00 1.22915151e-18 9.61075444e-06 2.50336037e-07
 3.72078620e-08 9.90000002e-01 0.00000000e+00]
```

Komentarz

Najlepsze rezultaty zostały osiągnięte przy alfa równym 1.0 i gamma rownym 0.1, najgorsze dla alfa równego 0.1 i gamma równego 0.99

✓ 0 s ukończono o 09:49