```
import numpy as np
import gym
import matplotlib.pyplot as plt
import tensorflow as tf
import keras
from keras.models import Sequential
from keras.layers import Dense


env = gym.make("FrozenLake-v0", map_name='4x4', is_slippery=False)
```

W srodowisku FrozenLake **stany** reprezentowane są za pomocą cyfr **0,1,2,...,15**. Na wejście sieci możemy podać **tensor o kształcie (1,16)**. W związku z tym musimy przekszatałcić stany do odpowieniej postaci. Robimy to w sposób opisany poniżej.

Wykorzystamy **macierz jednostkową o wymiarach 16x16**:

```
np.identity(16)
```

```
array([[1., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0.],
       [0., 1., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0.],
       [0., 0., 1., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0.],
       [0., 0., 0., 1., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0.],
       [0., 0., 0., 0., 1., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0.],
       [0., 0., 0., 0., 0., 1., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0.],
       [0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0., 0., 0., 0., 0., 0.],
       [0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0., 0., 0., 0., 0.],
       [0., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0., 0., 0., 0.],
       [0., 0., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0., 0., 0.],
       [0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0., 0.],
       [0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0.],
       [0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0.],
       [0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0.],
       [0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 1., 0.],
       [0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 1.]])
```

```
state = 0 #0-16
state = np.identity(16)[state]
```

```
state
```

```
array([1., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0.])
```

Wiersze z powyższej macierzy po **zmianie kształtu na (1,16)** będą odpowiednią reprezentacją **stanu**:

```
state = state.reshape(1,16)
state
```

```
array([[1., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0.]])
```

Sień neuronowa **aproksymująca funkcję Q** na wejściu otrzymuje **tensor o kształcie (1,16)**. UWAGA: neurony w warstwie wyjściowej mają **funkcję aktywacji f(x)=x** (DLACZEGO?):

```
model = Sequential()
model.add(Dense(units = 50, input_dim=16, activation='relu'))
model.add(Dense(units = 50, activation = "relu"))
model.add(Dense(units = 4, activation = "linear"))
```

Na wyjściu sieć **zwraca tensor o kształcie (1,4)**. Każda z czterech wartości to wartość **Q** dla stanu **s** i **każdej z możliwych akcji** (0-lewo,1-dół,2-prawo,3-góra):

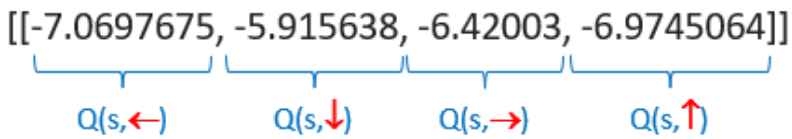


```
opt = tf.keras.optimizers.Adam(learning_rate=0.001)
#opt = keras.optimizers.SGD(learning_rate=0.001)

model.compile(loss='MSE',optimizer=opt)
model.summary()
```

```
Model: "sequential"
```

```
 Layer (type)                Output Shape              Param #
=================================================================
 dense (Dense)               (None, 50)                850

 dense_1 (Dense)             (None, 50)                2550

 dense_2 (Dense)             (None, 4)                 204

=================================================================
Total params: 3,604
Trainable params: 3,604
Non-trainable params: 0
_________________________________________________________________
```

Parametry uczenia:

```
train_episodes = 100
epsilon = 0.5
gamma = 0.99
```

Pętla treningowa:

```
Loss = []
Rewards = []
for e in range(train_episodes):
  total_reward = 0
  t = 0
  state = env.reset()
  state = np.identity(16)[state]
  state = np.reshape(state,[1,16])
  done = False
  while done == False:
    Qs = model.predict(state)[0]
    if np.random.rand()<epsilon:
      action = env.action_space.sample()
    else:
      action = np.argmax(Qs)
    next_state, reward, done, _ = env.step(action)
```

```
      next_state, reward, done, _ = env.step(action)
      if done:
        if reward == 1:
          reward = 5
        else:
          reward = -5
      else:
        reward = -1
      next_state = np.identity(16)[next_state]
      next_state = np.reshape(next_state, [1, 16])
      Qs_next = model.predict(next_state)[0]
      Qs = np.reshape(Qs,[1,4])
      Qs_target = np.copy(Qs)
      if done:
        y = reward
      else:
        y = reward + gamma*np.max(Qs_next)
      Qs_target[0][action] = y
      h = model.fit(state,Qs_target,epochs=1,verbose=0) #uczenie
      loss = h.history['loss'][0]
      state = next_state
      total_reward += reward
      t+=1
    if e%10==0:
      print("R=",total_reward," L=",loss)
    Rewards.append(total_reward) #zapis bledu i nagrod
    Loss.append(loss)

```

```
R= -8  L= 6.2203569412231445
R= -11  L= 5.017228126525879
R= -17  L= 2.5493221282958984
R= -6  L= 0.0003732536279130727
R= -7  L= 0.0502222515642643
R= -6  L= 0.021973993629217148
R= -8  L= 0.0012060540029779077
R= -6  L= 0.005624506622552872
R= -7  L= 0.0007596190553158522
R= -6  L= 0.8401821851730347
```

```
plt.subplot(211)
plt.ylabel('Suma nagród')
plt.title('Suma nagród w epizodzie')
```

```
    plt.title('Suma nagród w epizodzie')
    plt.plot(list(range(train_episodes)),Rewards,"b")

    plt.subplot(212)
    plt.xlabel('epizod')
    plt.ylabel('błąd')
    plt.title('Loss per epoch')
    plt.plot(list(range(train_episodes)),Loss,"r")

    plt.show()
```

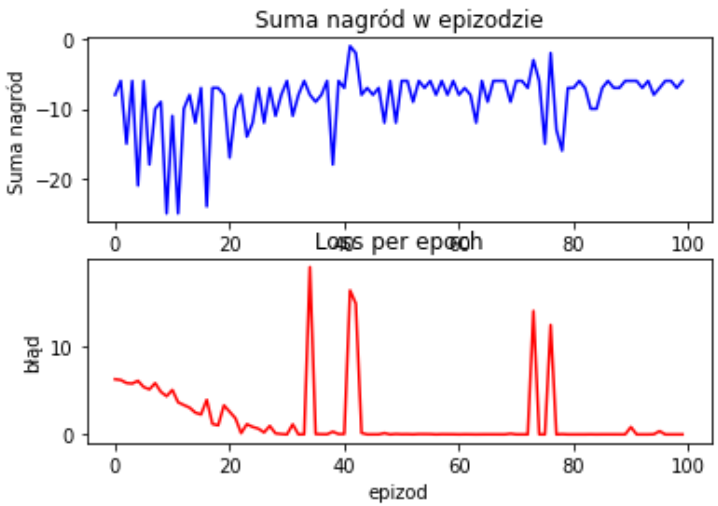

✓ 0 s ukończono o 09:52