Przykład 1 (liczenie gradientu)

```
import tensorflow as tf
```

Policz gradient (pochodną) funkcji $f(x) = 2x^2 + 3x + 4$ w punkcie 4.

Policz gradient funkcji $f(x,y) = 2x^3 + 3y^2 + 4$ w punkcie (4,5).


+ Tekst

```
x = . tf. Variable(4.0)
y = . tf. Variable(5.0)

with . tf. GradientTape() . as . tape:
... . f = . 2*(x**3)+3*(y**2)+4...
... . df_dx, df_dy = . tape.gradient(f,(x,y))

print(df_dx.numpy())
print(df_dy.numpy())
```

Przykład 2 (regresja liniowa - liczenie gradientów)



Wygenrujemy zbiór danych złożony z 1000 punktów.

```
number_of_points = 1000
x_point = []
y_point = []

a = 0.22
b = 0.78

for i in range(number_of_points):
    x = np.random.normal(0.0,0.5)
    y = (a*x+b)+np.random.normal(0.0,0.1)
    x_point.append(x)
    y_point.append(y)

plt.scatter(x_point,y_point,c='b')
plt.show()
```

```
1.2
      1.1
      1.0
       0.9
      0.8
  Zapisano pomyślnie.
reat_x - mp.array(x_poinc)
real_y = np.array(y_point)
Definicja błędu:
def loss_fn(real_y, pred_y):
```

```
return tf.reduce_mean((real_y - pred_y)**2)
```

Defincje parametrów modelu:

```
import random
a = tf.Variable(random.random())
b = tf.Variable(random.random())
```

Pętla treningowa:

```
Loss = []
epochs = 50
for _ in range(epochs):
 with tf.GradientTape() as tape:
   pred_y = a * real_x + b
   loss = loss_fn(real_y, pred_y)
```

```
Loss.append(loss.numpy())
  dloss_da, dloss_db = tape.gradient(loss,(a, b))
  a.assign_sub(dloss_da * 0.1) #a = a - alpha*dloss_da
 b.assign sub(dloss db * 0.1) #b = b - alpha*dloss db
 Zapisano pomyślnie.
     (0.10372553, 0.010425453)
print(a.numpy())
print(b.numpy())
     0.2878917
     0.7810024
plt.scatter(np.arange(epochs),Loss)
plt.show()
      0.10
      0.08
      0.06
```

20

10

30


0.04

0.02

0

```
max = np.max(x_point)
min = np.min(x_point)

X = np.linspace(min, max, num=10)
plt.plot(X,a.numpy()*X+b.numpy(),c='r')
plt.scatter(x_point,y_point,c="b")
plt.show()
```



Przykład 3 (regresja liniowa - Keras)

```
import keras
from keras.models import Sequential
from keras.layers import Dense
```

Definiujemy model:

```
model = Sequential()
```

Dodajemy **jedną warstwę** (Dense) z **jednym neuronem** (units=1) z **biasem** (use_bias=True) i **liniową funkcją aktywacji** (activation="linear"):

model.add(Dense(units = 1, use_bias=True, input_dim=1, activation = "linear"))

Definiujemy optymalizator i błąd (średni błąd kwadratowy - MSE). Współczynnik uczenia = 0.1

Zapisano pomyślnie. \times ing_rate=0.1)

Kompilacja modelu:

model.compile(loss='MSE',optimizer=opt)

Informacje o modelu:

model.summary()

Model: "sequential"

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 1)	2
Total params: 2		=============

Total params: 2
Trainable params: 2
Non-trainable params: 0


Ustalamy liczbę epok w czasie której model będzie uczony.

number_epochs=100

Proces uczenia:

```
h = model.fit(real_x,real_y, verbose=0, epochs=number_epochs, batch_size=1000)
```





Sprawdźmy jakie są wartości wag:

```
weights = model.get_weights()
a = weights[0][0][0]
b = weights[1][0] #bias
a,b
```

```
(0.23248206, 0.7835197)
max = np.max(x_point)
min = np.min(x_point)
X = np.linspace(min, max, num=10)
plt.plot(X,a*X+b,c='r')
 Zapisano pomyślnie.
      1.2
      1.1
      1.0
      0.9
      0.8
      0.7
      0.6
      0.5
```

→ Przykład 4 (regresja logistyczna - liczenie gradientów)

0.5

0.0

1.0

Zbiór danych:

-1.5

-1.0

```
x_label1 = np.random.normal(3, 1, 1000)
y_label1 = np.random.normal(2, 1, 1000)
x_label2 = np.random.normal(7, 1, 1000)
y_label2 = np.random.normal(6, 1, 1000)
```

```
xs = np.append(x_label1, x_label2)
ys = np.append(y_label1, y_label2)
labels = np.asarray([0.]*len(x_label1)+[1.]*len(x_label2))
plt.scatter(x label1, y label1, c='r', marker='x', s=20)
plt.scatter(x_label2, y_label2, c='g', marker='1', s=20)
 Zapisano pomyślnie.
      -2
                                                  10
```

Definiujemy funkcję błędu (entropia krzyżowa):


```
def loss_fn(label, label_model):
    return tf.reduce_mean(-label*tf.math.log(label_model)-(1-label)*tf.math.log(1-label_model))
```

Parametry modelu:

```
import random
a = tf.Variable(random.random())
b = tf.Variable(random.random())
c = tf.Variable(random.random())
```


Petla treningowa:

```
Loss = []
epochs = 2000
lr = 0.01
 Zapisano pomyślnie.
                                     b*vs + c)
    loss = loss fn(labels, labels model)
    Loss.append(loss.numpy())
  dloss da, dloss db, dloss dc = tape.gradient(loss,(a, b, c))
  a.assign_sub(lr*dloss_da)
  b.assign sub(lr*dloss db)
  c.assign sub(lr*dloss dc)
np.max(Loss),np.min(Loss)
     (1.2138839, 0.30223346)
print(a.numpy())
print(b.numpy())
print(c.numpy())
     0.0034050525
     0.6508277
     -2.0283709
plt.scatter(np.arange(epochs),Loss)
plt.show()
```



Sprawdzamy dla pewnego punktu:

```
x=8.0
y=6.0
plt.scatter(x_label1, y_label1, c='r', marker='x', s=20)
plt.scatter(x_label2, y_label2, c='g', marker='1', s=20)
plt.scatter([x],[y],c='b', marker='s')
plt.show()
```



```
tf.sigmoid(a*x + b*y + c).numpy()
     0.8703251
```

Przykład 5 (regresia logistyczna - Keras)

Zapisano pomyślnie.

Zbiór danych:

```
#zbiór czerowny
x_label1 = np.random.normal(3, 1, 1000)
y_label1 = np.random.normal(2, 1, 1000)

#zbiór zielony
x_label2 = np.random.normal(7, 1, 1000)
y_label2 = np.random.normal(6, 1, 1000)

xs = np.append(x_label1, x_label2)
ys = np.append(y_label1, y_label2)

plt.scatter(x_label1, y_label1, c='r', marker='x', s=20)
plt.scatter(x_label2, y_label2, c='g', marker='1', s=20)
plt.show()
```

```
8 -
6 -
```

Zbiór treningowy złożony jest z punktów:

Wartości oczekiwane: **0** dla zbioru **czerwonego**, **1** dla zbioru **zielonego**.

Definiujemy model:

```
model = Sequential()
model.add(Dense(units = 1, use_bias=True, input_dim=2, activation = "sigmoid"))

opt = tf.keras.optimizers.Adam(learning_rate=0.1)
#opt = keras.optimizers.SGD(learning_rate=0.001)

model.compile(loss='binary_crossentropy',optimizer=opt,metrics=['accuracy'])

Zapisano pomyślnie.
X
```

Layer (type)	Output Shape	Param #
		=======
dense_5 (Dense)	(None, 1)	3


Total params: 3
Trainable params: 3
Non-trainable params: 0

Pętla ucząca:

```
epochs = 1000
h = model.fit(data_points,labels, verbose=0, epochs=epochs, batch_size=100)

Loss = h.history['loss']

plt.scatter(np.arange(epochs),Loss)
plt.show()
```




Sprawdzamy dla punktu o współrzędnych:



x=7.0

y=6.0

```
plt.scatter(x_label1, y_label1, c='r', marker='x', s=20)
plt.scatter(x_label2, y_label2, c='g', marker='1', s=20)
plt.scatter([x],[y],c='b', marker='s')
plt.show()
```



```
model.predict([[x,y]])
array([[1.]], dtype=float32)
```

Zapisano pomyślnie.